

# 规范终图

## 规范型

一边写体条件独立性.

$$(X_A \perp X_B \mid X_C)$$

A, B, C 为互不相交的集合

关注对象

根率图

高维随机变量

$$P(x_1, \dots, x_p)$$

边缘概率  $P(x_i)$

条件概率  $P(x_j | x_i)$

basic rules

Sum rule:  $P(x_1) = \int P(x_1, x_2) dx_2$

product rule:  $P(x_1) \cdot P(x_2 | x_1) = P(x_2) \cdot P(x_1 | x_2)$

chain rule:  $P(x_1, x_2, \dots, x_p) = \left[ \prod_{i=1}^p P(x_i | x_1, \dots, x_{i-1}) \right] \cdot P(x_1)$

Bayesian Rule:  $P(x_2 | x_1) = \frac{P(x_1, x_2)}{P(x_1)} = \frac{P(x_2) \cdot P(x_1 | x_2)}{\int P(x_1, x_2) dx_2}$

$$= \frac{P(x_2) \cdot P(x_1 | x_2)}{\int P(x_1, x_2) dx_2}$$

困难: 维度高, 计算复杂.  $P(x_1, x_2, \dots, x_p)$  计算量太大.

简化

Naive Bayes:  $P(x | y) = \prod_{i=1}^p P(x_i | y)$

维度之间相互独立

假设太强

$$P(x_1, \dots, x_p) = \prod_{i=1}^p P(x_i)$$

Markov property  
Markov (假设)  
Markov (假设)  
 $x_j \perp x_{i+1} | x_i, i < j$   
(只与前一项有关)

条件独立性


$x_A \perp x_B | x_C$   
( $x_A, x_B, x_C$  是集合且不相交。)

$x_1, \dots, x_p \rightarrow$  - 隐含假设  
依赖关系太过简单

核心性质

马尔可夫链的推广

通过概率图  $\rightarrow$  因子分解



$$P(a, b, c) = P(a)P(b|a)P(c|a)$$

$$P(a, b, c) = P(a)P(b|a)P(c|ab)$$

chain rule

$$\therefore P(a)P(b|a)P(c|a) = P(a)P(b|a)P(c|a, b)$$

$$\Rightarrow P(c|a) = P(c|a, b)$$

$$\Rightarrow c \perp b \mid a$$

因为给定  $a$ , 不管  $b$  发没发生,  $c$  不受影响。

根线图

Representation 表示

- 有向图 Bayesian Network
- 高斯图 (连续) Gaussian BN, Gaussian MV
- 无向图 Markov Network

Inference 推断

精确推断

近似推断

- 确定性近似 (变分自机)
- 随机近似 (MCMC)

Learning 学习

参数学习

- 实值数据
- 隐变量

结构学习

直接通过随机变量  
经过随机排列之后  
得到的图列出的  
分解式。

Bayesian network

$P(X_1, \dots, X_p) = P(X_1) \prod_{i=2}^p P(X_i | X_1, \dots, X_{i-1}) \Rightarrow$  chain Rule

有向图

条件独立性:  $X_A \perp X_C \mid X_B$  (此处  $X_A, X_B, X_C$  均为 connection)

因子分解:  $P(X_1, \dots, X_p) = \prod_{i=1}^p P(X_i \mid X_{pa(i)})$

$\hookrightarrow$  为  $X_i$  的父节点集合

tail  $\rightarrow$  head

case 1: (head to tail) 若 b 被观测, 必经堵塞, a, c 独立。

$a \rightarrow b \rightarrow c \Rightarrow a \perp c \mid b$

case 2: (tail to tail) 若 c 被观测, 必经堵塞, a, b 独立。

$a \leftarrow c \leftarrow b \Rightarrow a \perp b \mid c$

case 3: (head to head) 若 c 被观测, a, b 不独立。


$a \rightarrow c \leftarrow b \Rightarrow a, b \text{ 不独立}$

默认情况: a, b 独立, c 被观测后, a, b 不独立。

$a \perp b \mid c$

D-separation

pre.  $X_A, X_B, X_C$  都为随机变量集合且相互之间不相关。



$\Rightarrow$  全局 Markov property


$$\begin{aligned}
 p(x_i | x_{-i}) &= \frac{p(x_i, x_{-i})}{p(x_{-i})} = \frac{p(x)}{\int_{x_i} p(x) dx_i} \\
 &\stackrel{\text{边缘相等}}{=} \frac{p(x)}{\int_{x_i} p(x) dx_i} \\
 &\stackrel{\text{因子分解}}{=} \frac{\prod_{j=1}^D p(x_j | x_{pa(x_j)})}{\int_{x_i} \prod_{j=1}^D p(x_j | x_{pa(x_j)}) dx_i} \\
 &= \frac{f(A) \cdot f(\bar{A})}{f(\bar{A}) - \int_{x_i} f(A) dx_i} = \int_{\bar{A}} f(A)
 \end{aligned}$$

$x_i$  与其他所有随机变量的关系。

$A = \text{与 } x_i \text{ 有关}$   
 $\bar{A} = \text{与 } x_i \text{ 无关}$   
 所有父节点集合

$\Rightarrow$  证明  $x_i$  与其他随机变量的关系与自身有关系的有关。

図示:



$$P(x_i | x_{pa(i)})$$

$$P(x_{child(i)} | x_i, x_{pa(child(i))})$$

$\Rightarrow$  Markov  
Blanket

